

**ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC VÀ KỸ THUẬT THÔNG TIN**



BÁO CÁO ĐỒ ÁN

Đề tài:

**HỆ THỐNG PHÂN TÍCH VÀ GOM CỤM ĐÁNH GIÁ
TRỰC TUYẾN NHẪM CẢNH BÁO KHỦNG HOẢNG
THƯƠNG HIỆU**

GVHD: ThS. Mai Xuân Hùng

Nhóm sinh viên thực hiện:

- | | |
|--------------------------|----------------|
| 1. Lê Thế Thắng | MSSV: 23730125 |
| 2. Lê Hải Phúc | MSSV: 23730116 |
| 3. Nguyễn Phạm Thủy Tiên | MSSV: 23730131 |
| 4. Lâm Thanh Đức | MSSV: 23730078 |

Tp. Hồ Chí Minh, 05/2026

NHẬN XÉT CỦA GIÁO VIÊN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

....., ngày tháng năm 20...

Người nhận xét

(Ký tên và ghi rõ họ tên)

Lời mở đầu

Ngày nay, các nền tảng thương mại điện tử và trực tuyến đã trở thành không gian tương tác phổ biến giữa khách hàng và thương hiệu. Lượng dữ liệu văn bản từ các đánh giá trực tuyến chứa đựng nhiều thông tin hữu ích về trải nghiệm và mức độ hài lòng của người dùng. Tuy nhiên, lượng dữ liệu lớn này cũng mang đến những thách thức trong việc quản lý. Một trải nghiệm dịch vụ không tốt có thể nhanh chóng lan truyền thông qua các đánh giá tiêu cực, dẫn đến nguy cơ khủng hoảng thương hiệu và ảnh hưởng nghiêm trọng đến uy tín của tổ chức.

Do việc rà soát hàng ngàn đánh giá thủ công tốn rất nhiều thời gian và nguồn lực, nhóm quyết định thực hiện đề tài "**Xây dựng hệ thống phân tích và gom cụm đánh giá trực tuyến nhằm cảnh báo khủng hoảng thương hiệu**". Đồ án ứng dụng các kỹ thuật khai phá dữ liệu, xử lý ngôn ngữ tự nhiên (NLP) và học máy để phân tích dữ liệu đánh giá tiếng Việt. Hệ thống tiến hành phân loại cảm xúc (Tích cực, Tiêu cực, Trung lập) và phát hiện các cụm chủ đề bằng thuật toán K-Means (kết hợp phương pháp Elbow) và LDA. Dựa trên kết quả phân tích, hệ thống cung cấp công cụ cảnh báo sớm sử dụng điểm số rủi ro và đường trung bình động, hỗ trợ người quản trị nhận diện sớm các đợt bùng phát đánh giá tiêu cực.

Mục lục

1	Tổng quan	8
1.1	Bối cảnh và Lý do chọn đề tài	8
1.2	Mục tiêu nghiên cứu	8
1.3	Đối tượng và Phạm vi nghiên cứu	9
1.4	Bố cục của báo cáo	9
2	Cơ sở lý thuyết	11
2.1	Tổng quan về Khai phá dữ liệu (Data Mining)	11
2.2	Tiền xử lý dữ liệu văn bản tiếng Việt	11
2.2.1	Làm sạch dữ liệu (Data Cleaning)	11
2.2.2	Tách từ tiếng Việt (Word Tokenization)	12
2.2.3	Loại bỏ từ dừng	12
2.3	Biểu diễn đặc trưng văn bản: TF-IDF	13
2.3.1	Khái niệm TF-IDF	13
2.3.2	Công thức tổng hợp	13
2.4	Thuật toán Phân lớp: Naive Bayes	14
2.4.1	Cơ sở toán học	14
2.4.2	Kỹ thuật làm tròn Laplace	14
2.4.3	Biến thể Multinomial Naive Bayes	15
2.5	Thuật toán Gom cụm (Clustering)	15
2.5.1	Thuật toán K-Means	15
2.5.2	Thuật toán LDA (Latent Dirichlet Allocation)	17
2.5.3	So sánh K-Means và LDA trong thực nghiệm	18
2.5.4	Giảm chiều dữ liệu và trực quan hóa cụm (Truncated SVD)	18
3	Phương pháp thực hiện	20

3.1	Kiến trúc tổng thể của hệ thống	20
3.1.1	Module Huấn luyện mô hình (<code>train.py</code>)	20
3.1.2	Module Phân tích (<code>app.py</code>)	21
3.1.3	Các tham số cấu hình TF-IDF trên giao diện	21
3.2	Lý do lựa chọn thuật toán	22
3.2.1	Sự phối hợp giữa Học có giám sát (Naive Bayes) và Học không giám sát (K-Means/LDA)	23
3.3	Quy trình tiền xử lý chi tiết	24
3.4	Công thức đánh giá Rủi ro khủng hoảng	24
3.4.1	Cấu thành công thức	24
3.4.2	Phát hiện bất thường bằng Đường trung bình động	25
3.5	Định dạng Bộ dữ liệu đầu vào	26
4	Thực nghiệm và Đánh giá	28
4.1	Môi trường và Công cụ phát triển	28
4.2	Bộ dữ liệu thực nghiệm	28
4.3	Kết quả Phân tích cảm xúc	29
4.3.1	Huấn luyện mô hình Naive Bayes	29
4.3.2	Kết quả dự đoán trên Dashboard	29
4.4	Kết quả Gom cụm chủ đề	31
4.4.1	Tối ưu hóa số lượng cụm bằng Elbow Method	31
4.4.2	Trực quan hóa kết quả gom cụm	31
4.4.3	So sánh định tính giữa K-Means và LDA	33
4.5	Kết quả Theo dõi và Cảnh báo Khủng hoảng	34
4.5.1	Biểu đồ chuỗi thời gian tương tác	34
4.5.2	Vai trò của các tham số điều chỉnh	35
4.5.3	Phân tích nguồn gây khủng hoảng theo kênh	35
5	Kết luận	36
5.1	Kết quả đạt được	36

5.2	Hạn chế của hệ thống	36
5.3	Hướng phát triển	37
5.4	Kết luận chung	37
Tài liệu tham khảo		39
A Phụ lục hình ảnh		41
A.1	Giao diện tổng quan và cấu hình hệ thống	41
A.2	Giao diện phân tích và cảnh báo chuyên sâu	43

Danh sách bảng

2.1	So sánh thực nghiệm đặc điểm K-Means và LDA	18
3.1	Các tham số cấu hình TF-IDF trên giao diện	22
3.2	Các tham số cấu hình cảnh báo khủng hoảng trên giao diện	26
4.1	Cấu hình môi trường phát triển	28

Danh sách hình vẽ

4.1	Biểu đồ cột phân bố cảm xúc đánh giá sau khi dự đoán bằng Naive Bayes	30
4.2	Biểu đồ tròn tỷ lệ phần trăm phân bố cảm xúc đánh giá sau khi dự đoán bằng Naive Bayes	30
4.3	Đồ thị phương pháp Elbow: Giá trị WCSS theo số cụm K	31
4.4	Mây từ vựng đại diện cho các cụm chủ đề	32
4.5	Biểu đồ cột thống kê số lượng đánh giá theo từng cụm chủ đề K-Means	32
4.6	Trực quan hóa không gian các cụm đánh giá bằng phương pháp Truncated SVD	33
4.7	So sánh trực quan kết quả gom cụm giữa K-Means và LDA	33
4.8	Biểu đồ chuỗi thời gian: Diễn biến đánh giá tiêu cực và cảnh báo bùng phát . .	35
A.1	Giao diện Dashboard tổng quan sau khi nạp dữ liệu thành công. Bảng điều khiển (Sidebar) cho phép cấu hình tham số K-Means/LDA, chọn cột thời gian, nền tảng và ngưỡng cảnh báo khủng hoảng.	41
A.2	Chi tiết thanh điều hướng (Sidebar) với tùy chọn "Tự động chọn K tối ưu (Elbow Method)" được kích hoạt, cho phép hệ thống tự nội suy số cụm tốt nhất.	42
A.3	Kết quả phân tích cảm xúc đánh giá bằng mô hình Naive Bayes, hiển thị thống kê tổng quan và chỉ số rủi ro (Risk Score).	43
A.4	Đồ thị Elbow tối ưu hóa K tự động: Hệ thống đánh dấu điểm cùi chỏ (ngôi sao đỏ) bằng thuật toán nội suy khoảng cách lớn nhất.	43
A.5	Hiển thị các cụm chủ đề: Biểu đồ cột phân bố số lượng đánh giá và Đám mây từ khóa (WordCloud) đại diện cho các từ có trọng số TF-IDF cao nhất.	44
A.6	Biểu đồ cảnh báo khủng hoảng tương tác Plotly: Hiển thị đường xu hướng đánh giá tiêu cực, đường trung bình động (Moving Average) và các điểm bùng phát (Anomaly) được đánh dấu bằng ngôi sao đỏ.	45

1. Tổng quan

1.1. Bối cảnh và Lý do chọn đề tài

Hiện nay, các nền tảng thương mại điện tử và dịch vụ trực tuyến là nơi tập trung lượng lớn đánh giá của người dùng. Dữ liệu đánh giá trực tuyến này đóng vai trò quan trọng trong việc giúp các doanh nghiệp nắm bắt nhu cầu khách hàng và cải thiện chất lượng dịch vụ [1]. Do đó, các kỹ thuật khai phá dữ liệu văn bản đang được quan tâm nghiên cứu để hỗ trợ phân tích lượng thông tin lớn này.

Bên cạnh những lợi ích, việc quản lý luồng ý kiến của khách hàng cũng đối mặt với khó khăn khi các đánh giá tiêu cực có thể lan truyền nhanh chóng, dẫn đến nguy cơ khủng hoảng thương hiệu. Việc rà soát thủ công lượng lớn đánh giá mỗi ngày tốn rất nhiều thời gian và nhân lực, đồng thời khó đáp ứng được yêu cầu cập nhật liên tục.

Từ thực tế đó, nhóm quyết định thực hiện đề tài "**Xây dựng hệ thống phân tích và gom cụm đánh giá trực tuyến nhằm cảnh báo khủng hoảng thương hiệu**". Đề tài ứng dụng các kỹ thuật Khai phá dữ liệu và Xử lý ngôn ngữ tự nhiên để xây dựng một hệ thống phân tích đánh giá tiếng Việt. Hệ thống giúp phân loại cảm xúc, gom cụm các chủ đề phàn nàn/đánh giá và cung cấp cơ chế cảnh báo dựa trên số lượng đánh giá tiêu cực. Giải pháp này nhằm hỗ trợ thương hiệu theo dõi và phản hồi kịp thời các vấn đề tiềm ẩn từ phía người dùng.

1.2. Mục tiêu nghiên cứu

Đề án hướng đến việc xây dựng ứng dụng phân tích văn bản tiếng Việt với các mục tiêu cụ thể như sau:

- **Tiền xử lý và biểu diễn dữ liệu:** Áp dụng các kỹ thuật làm sạch văn bản, chuẩn hóa từ ngữ tiếng Việt và biểu diễn dữ liệu dưới dạng vector bằng mô hình TF-IDF.
- **Gom cụm chủ đề:** Sử dụng hai thuật toán học máy không giám sát là K-Means và LDA để tự động nhóm các đánh giá có nội dung tương đồng, giúp dễ dàng nắm bắt các chủ đề thảo luận chính.
- **Phân loại cảm xúc:** Xây dựng mô hình Naive Bayes để tự động phân loại các đánh giá

thành ba nhóm: Tích cực, Tiêu cực và Trung lập.

- **Cảnh báo khủng hoảng:** Xây dựng công thức tính điểm rủi ro và sử dụng đường trung bình động để nhận diện sự gia tăng đột biến của các luồng ý kiến tiêu cực.
- **Giao diện trực quan:** Xây dựng giao diện web (bằng Streamlit) hiển thị báo cáo thông qua biểu đồ, WordCloud và danh sách cảnh báo.

1.3. Đối tượng và Phạm vi nghiên cứu

- **Đối tượng nghiên cứu:**
 - **Về dữ liệu:** Các bình luận, đánh giá của khách hàng bằng tiếng Việt trên các nền tảng trực tuyến. Nhóm tận dụng các bộ dữ liệu có sẵn từ cộng đồng để huấn luyện mô hình, kết hợp với một bộ dữ liệu tự thu thập và xử lý để chạy thực nghiệm.
 - **Về thuật toán:** Nghiên cứu và áp dụng các phương pháp học máy cơ bản như TF-IDF, Naive Bayes, K-Means và LDA.
- **Phạm vi nghiên cứu:** Đồ án chỉ tập trung xử lý dữ liệu văn bản tiếng Việt được lưu sẵn dưới dạng file CSV. Do giới hạn về thời gian thực hiện, nhóm chỉ tập trung vào các thuật toán máy học truyền thống, chưa đi sâu vào các mô hình học sâu (Deep Learning) hay xử lý dữ liệu lớn theo thời gian thực.

1.4. Bố cục của báo cáo

Báo cáo đồ án bao gồm 5 chương:

- **Chương 1 - Tổng quan:** Trình bày bối cảnh, lý do chọn đề tài, mục tiêu và phạm vi nghiên cứu.
- **Chương 2 - Cơ sở lý thuyết:** Cung cấp lý thuyết về xử lý ngôn ngữ tự nhiên tiếng Việt, mô hình TF-IDF và các thuật toán phân lớp (Naive Bayes), gom cụm (K-Means, LDA).
- **Chương 3 - Phương pháp thực hiện:** Trình bày quy trình xử lý dữ liệu, kiến trúc hệ thống và cách xây dựng cơ chế cảnh báo rủi ro.
- **Chương 4 - Thực nghiệm và Đánh giá:** Đánh giá kết quả huấn luyện mô hình phân loại, so sánh kết quả gom cụm và tính năng cảnh báo của hệ thống qua giao diện web.

- **Chương 5 - Kết luận:** Tóm tắt các công việc đã thực hiện, những điểm hạn chế và hướng phát triển đề xuất.

2. Cơ sở lý thuyết

2.1. Tổng quan về Khai phá dữ liệu (Data Mining)

Khai phá dữ liệu (Data Mining) là quá trình khám phá và trích xuất những mẫu, xu hướng và tri thức tiềm ẩn có giá trị từ các tập dữ liệu khổng lồ [2]. Khác với thống kê truyền thống vốn thường kiểm chứng một giả thuyết đã biết trước, Khai phá dữ liệu hướng tới việc *phát hiện tri thức mới* mà con người chưa biết từ dữ liệu.

Quy trình Khai phá dữ liệu thường tuân theo mô hình **KDD** (Knowledge Discovery in Databases) gồm các bước: Thu thập dữ liệu → Tiền xử lý → Biến đổi → Khai phá → Đánh giá và trình bày kết quả [2]. Trong bài toán phân tích mạng xã hội của đề án này, Data Mining là công cụ chính giúp chuyển hóa những luồng bình luận phi cấu trúc thành các thông tin có thể định lượng và phân tích được. Các kỹ thuật chính được ứng dụng trong đề án bao gồm:

- **Gom cụm (Clustering):** Nhóm các bình luận có nội dung tương đồng vào cùng một cụm chủ đề. Đây là kỹ thuật học không giám sát, không yêu cầu dữ liệu gán nhãn trước.
- **Phân lớp (Classification):** Gán nhãn cảm xúc (Tích cực, Tiêu cực, Trung lập) cho từng bình luận. Đây là kỹ thuật học có giám sát, yêu cầu một tập huấn luyện đã được gán nhãn sẵn.

Sự kết hợp này giúp hệ thống vừa hiểu được “người dùng đang nói về chủ đề gì”, vừa biết được “thái độ của họ ra sao”.

2.2. Tiền xử lý dữ liệu văn bản tiếng Việt

Dữ liệu văn bản trên mạng xã hội thường chứa rất nhiều nhiễu, do đó bước tiền xử lý là bắt buộc nhằm chuẩn hóa dữ liệu đầu vào trước khi đưa vào các thuật toán khai phá [1].

2.2.1. Làm sạch dữ liệu (Data Cleaning)

Các bình luận trên mạng xã hội thường chứa nhiều thành phần không mang thông tin ngữ nghĩa, bao gồm: emoji, URL, email, thẻ mention (@), hashtag (#), số và ký tự đặc biệt. Quy trình làm sạch gồm:

1. Chuyển toàn bộ văn bản về chữ thường để đồng nhất hóa.
2. Loại bỏ URL (dạng `http://...` hoặc `www...`), địa chỉ email.
3. Loại bỏ các ký tự đặc biệt và số bằng biểu thức chính quy (Regex).
4. Chuẩn hóa khoảng trắng dư thừa.

Kết quả sau bước này là một chuỗi văn bản thuần túy, chỉ giữ lại các từ có ý nghĩa ngữ nghĩa.

2.2.2. Tách từ tiếng Việt (Word Tokenization)

Trong tiếng Việt, một từ có thể bao gồm nhiều âm tiết (ví dụ: “khủng hoảng” gồm 2 âm tiết, “dịch vụ khách hàng” gồm 4 âm tiết). Nếu chỉ tách theo khoảng trắng như tiếng Anh, các từ ghép sẽ bị phá vỡ cấu trúc ngữ nghĩa. Do đó, việc tách từ chính xác là yếu tố quyết định chất lượng đầu vào cho các mô hình khai phá.

Đồ án sử dụng thư viện **Underthesea** [3], một bộ công cụ NLP mã nguồn mở chuyên dụng cho tiếng Việt. Underthesea sử dụng các mô hình học máy đã được huấn luyện trên kho ngữ liệu tiếng Việt lớn để nhận diện ranh giới từ, đồng thời nối các âm tiết thuộc cùng một từ ghép bằng dấu gạch dưới. Ví dụ:

“Dịch vụ giao hàng quá chậm” → dịch_vụ giao_hàng quá chậm

2.2.3. Loại bỏ từ dừng

Từ dừng (Stopwords) là các từ xuất hiện nhiều trong văn bản nhưng ít mang ý nghĩa, ví dụ: “là”, “thì”, “mà”, “của”, “bởi_vì”. Việc loại bỏ tập từ dừng mang lại hai lợi ích quan trọng:

- **Giảm chiều không gian đặc trưng**, từ đó tăng tốc độ tính toán cho các thuật toán vector hóa và gom cụm.
- **Tăng chất lượng kết quả** vì các thuật toán sẽ tập trung vào những từ khóa mang thông tin cốt lõi, phản ánh đúng chủ đề và cảm xúc của bình luận.

Trong đồ án, tập từ dừng tiếng Việt gồm hơn 80 từ phổ biến được xây dựng thủ công, bao gồm cả một số từ tiếng Anh thường gặp trong dữ liệu mạng xã hội Việt Nam.

2.3. Biểu diễn đặc trưng văn bản: TF-IDF

Sau tiền xử lý, văn bản cần được chuyển hóa thành các vector số học để các thuật toán học máy có thể tính toán. Phương pháp **TF-IDF** (Term Frequency – Inverse Document Frequency) [4] là một trong những kỹ thuật biểu diễn văn bản kinh điển và hiệu quả nhất cho các bài toán phân loại và gom cụm văn bản.

2.3.1. Khái niệm TF-IDF

Ý tưởng cốt lõi của TF-IDF là: *một từ càng quan trọng nếu nó xuất hiện nhiều trong một tài liệu cụ thể nhưng lại hiếm gặp trong toàn bộ tập dữ liệu*. Trọng số TF-IDF được tính qua hai thành phần:

- **TF (Term Frequency):** Tần suất xuất hiện tương đối của từ t trong tài liệu d :

$$TF(t, d) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}} \quad (2.1)$$

trong đó $f_{t,d}$ là số lần từ t xuất hiện trong tài liệu d .

- **IDF (Inverse Document Frequency):** Đo lường mức độ đặc trưng của từ t trên toàn bộ tập tài liệu D . Từ nào xuất hiện trong càng nhiều tài liệu thì giá trị IDF càng thấp:

$$IDF(t, D) = \log \left(\frac{N}{|\{d \in D : t \in d\}|} \right) \quad (2.2)$$

trong đó $N = |D|$ là tổng số tài liệu trong tập.

2.3.2. Công thức tổng hợp

Trọng số TF-IDF cuối cùng của từ t trong tài liệu d được tính bằng tích:

$$TF\text{-}IDF(t, d, D) = TF(t, d) \times IDF(t, D) \quad (2.3)$$

Nhờ cơ chế này, TF-IDF tự động làm nổi bật các từ khóa đặc trưng riêng của từng bình luận (ví dụ: “hàng_giả”, “hoàn_tiền”) trong khi giảm trọng số của những từ xuất hiện quá phổ biến (ví dụ: “sản_phẩm”, “đơn_hàng”) mà không mang nhiều ý nghĩa phân biệt. Kết quả của

bước vector hóa TF-IDF là một **ma trận thưa** có kích thước $n \times m$, với n là số bình luận và m là số từ vựng được chọn.

2.4. Thuật toán Phân lớp: Naive Bayes

Phân tích cảm xúc trong đồ án được giải quyết thông qua bài toán phân lớp. **Naive Bayes** là thuật toán phân lớp xác suất có giám sát, dựa trên Định lý Bayes với giả định “ngây thơ” rằng các đặc trưng độc lập có điều kiện với nhau khi biết trước nhãn lớp [5].

2.4.1. Cơ sở toán học

Xác suất hậu nghiệm để một tài liệu $d = (t_1, t_2, \dots, t_n)$ thuộc về nhãn cảm xúc c được tính theo Định lý Bayes:

$$P(c|d) = \frac{P(d|c) \cdot P(c)}{P(d)} \quad (2.4)$$

Với giả định Naive (các từ độc lập có điều kiện), ta có:

$$P(d|c) = \prod_{i=1}^n P(t_i|c) \quad (2.5)$$

Do $P(d)$ là hằng số đối với mọi lớp c , bài toán phân lớp quy về tìm lớp có xác suất hậu nghiệm lớn nhất:

$$\hat{c} = \arg \max_{c \in C} P(c) \prod_{i=1}^n P(t_i|c) \quad (2.6)$$

trong đó $C = \{\text{Tích cực, Tiêu cực, Trung lập}\}$ là tập nhãn cảm xúc.

2.4.2. Kỹ thuật làm trơn Laplace

Trong thực tế, khi gặp một từ t_i chưa từng xuất hiện trong tập huấn luyện của nhãn c , xác suất $P(t_i|c) = 0$ sẽ khiến toàn bộ tích bằng 0, dẫn đến phân lớp sai. Kỹ thuật **Laplace Smoothing** được áp dụng để khắc phục:

$$P(t_i|c) = \frac{\text{count}(t_i, c) + 1}{\sum_{t \in V} \text{count}(t, c) + |V|} \quad (2.7)$$

trong đó V là tập từ vựng, $|V|$ là kích thước tập từ vựng.

2.4.3. Biến thể Multinomial Naive Bayes

Đồ án sử dụng biến thể **Multinomial Naive Bayes**, phù hợp với bài toán phân loại văn bản khi dữ liệu đầu vào là các vector đếm tần suất từ hoặc trọng số TF-IDF. Biến thể này mô hình hóa mỗi tài liệu như một phân phối đa thức trên tập từ vựng. Ưu điểm nổi bật của Multinomial NB là tốc độ huấn luyện và dự đoán nhanh, phù hợp với yêu cầu xử lý gần thời gian thực trên giao diện web của hệ thống.

2.5. Thuật toán Gom cụm (Clustering)

Gom cụm là kỹ thuật Khai phá dữ liệu không giám sát, nhằm tự động nhóm các đối tượng (đánh giá) có sự tương đồng cao về ngữ nghĩa vào cùng một cụm mà không cần dữ liệu nhãn trước. Đồ án sử dụng hai thuật toán gom cụm thuộc hai trường phái khác nhau để so sánh và đánh giá.

2.5.1. Thuật toán K-Means

K-Means [6] là thuật toán phân cụm dựa trên khoảng cách, chia dữ liệu thành K cụm khác nhau và không chồng lấn. Trong đồ án này, các đánh giá sau khi được biểu diễn bằng vector TF-IDF sẽ được K-Means phân nhóm dựa trên độ tương đồng nội dung.

Hàm mục tiêu và khoảng cách hình học

K-Means hoạt động bằng cách giảm thiểu tổng bình phương khoảng cách từ mỗi điểm dữ liệu $\mathbf{x}_i$ đến tâm cụm μ_j gần nhất của nó. Chỉ số này được gọi là WCSS (Within-Cluster Sum of Squares):

$$J = \sum_{j=1}^K \sum_{\mathbf{x}_i \in C_j} \|\mathbf{x}_i - \mu_j\|^2 \quad (2.8)$$

Trong đó C_j là tập hợp các điểm dữ liệu trong cụm thứ j , còn μ_j là vector đại diện cho tâm của cụm đó.

Do ma trận đặc trưng TF-IDF được chuẩn hóa chuẩn L2 nên độ dài mỗi vector đều bằng 1 ($\|\mathbf{x}_i\|_2 = 1$). Khi đó, bình phương khoảng cách Euclidean giữa hai điểm dữ liệu $\mathbf{x}_i$ và $\mathbf{x}_k$ được tính như sau:

$$\|\mathbf{x}_i - \mathbf{x}_k\|^2 = \|\mathbf{x}_i\|^2 + \|\mathbf{x}_k\|^2 - 2\mathbf{x}_i^T \mathbf{x}_k = 2 - 2\cos(\mathbf{x}_i, \mathbf{x}_k) \quad (2.9)$$

Công thức này cho thấy việc tối thiểu hóa khoảng cách Euclidean tương đương với việc tối đa hóa độ tương đồng Cosine ($\cos(\mathbf{x}_i, \mathbf{x}_k)$). Do đó, mặc dù K-Means sử dụng khoảng cách hình học thông thường, thuật toán vẫn hoạt động rất hiệu quả khi gom cụm dữ liệu văn bản.

Các bước thực hiện thuật toán

Thuật toán K-Means được thực hiện lặp qua các bước sau:

1. **Bước 1 (Khởi tạo):** Chọn ngẫu nhiên K điểm trong không gian làm các tâm cụm ban đầu $\mu_1, \dots, \mu_K$.
2. **Bước 2 (Gán cụm):** Tính khoảng cách từ từng điểm dữ liệu $\mathbf{x}_i$ đến tất cả các tâm cụm và xếp điểm đó vào cụm có tâm gần nhất:

$$c_i = \arg \min_{j \in \{1, \dots, K\}} \|\mathbf{x}_i - \mu_j\|^2 \quad (2.10)$$

3. **Bước 3 (Cập nhật tâm):** Tính lại tọa độ tâm cụm μ_j bằng cách lấy trung bình cộng tọa độ các điểm thuộc cụm đó:

$$\mu_j = \frac{1}{|C_j|} \sum_{\mathbf{x}_i \in C_j} \mathbf{x}_i \quad (2.11)$$

4. **Bước 4 (Dừng hoặc lặp):** Lặp lại Bước 2 và Bước 3 cho đến khi vị trí các tâm cụm không thay đổi (hội tụ) hoặc đạt giới hạn số vòng lặp.

Phương pháp Elbow xác định số cụm K

Để tìm số cụm K tối ưu, đồ án sử dụng phương pháp Elbow. Hệ thống sẽ chạy thử K-Means với các giá trị K tăng dần (từ 2 đến 10) và ghi nhận giá trị WCSS tương ứng. Khi biểu diễn WCSS theo K trên đồ thị, điểm gãy khúc làm tốc độ giảm WCSS chững lại rõ rệt (giống hình khuỷu tay) chính là giá trị K phù hợp nhất cho tập dữ liệu.

Đánh giá kết quả bằng hệ số Silhouette

Hệ số Silhouette được dùng để đánh giá định lượng chất lượng phân cụm. Với mỗi điểm dữ liệu i , hệ số Silhouette s_i được tính bằng công thức:

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)} \quad (2.12)$$

Trong đó:

- a_i là khoảng cách trung bình từ điểm i đến các điểm khác trong cùng cụm.
- b_i là khoảng cách trung bình ngắn nhất từ điểm i đến các điểm thuộc cụm khác gần nhất.

Hệ số s_i có giá trị từ -1 đến 1 . Giá trị gần 1 chứng tỏ điểm dữ liệu được phân vào cụm rất tốt (nằm xa cụm khác và gần các điểm cùng cụm). Giá trị gần 0 hoặc âm phản ánh các cụm bị chồng lấn hoặc phân sai cụm. Hệ số Silhouette trung bình của toàn bộ tập dữ liệu phản ánh chất lượng gom cụm tổng thể.

2.5.2. Thuật toán LDA (Latent Dirichlet Allocation)

Khác với K-Means thực hiện phân cụm cứng (mỗi đánh giá chỉ nằm trong đúng một cụm), thuật toán LDA [7] thực hiện phân cụm mềm, cho phép một đánh giá thuộc về nhiều chủ đề khác nhau với các tỷ lệ xác suất tương ứng.

Nguyên lý hoạt động

LDA giả định rằng mỗi tài liệu được tạo ra từ một phân phối xác suất trên các chủ đề, và mỗi chủ đề lại được đặc trưng bởi một phân phối xác suất trên các từ vựng:

1. Mỗi tài liệu d được đại diện bởi một phân phối chủ đề $\theta_d \sim \text{Dirichlet}(\alpha)$.
2. Mỗi chủ đề k được đại diện bởi một phân phối từ vựng $\phi_k \sim \text{Dirichlet}(\beta)$.

Siêu tham số α kiểm soát mức độ tập trung chủ đề của tài liệu (giá trị α nhỏ nghĩa là mỗi tài liệu chỉ tập trung vào một vài chủ đề nhất định). Siêu tham số β kiểm soát sự phân bố từ vựng của chủ đề (giá trị β nhỏ nghĩa là mỗi chủ đề chỉ xoay quanh một số từ khóa đặc trưng).

Phân tích chủ đề

Dựa trên tập từ vựng thực tế trong các tài liệu, LDA sử dụng phương pháp suy diễn xấp xỉ (như lấy mẫu Gibbs - Gibbs Sampling) để tính toán ngược lại phân phối θ_d và ϕ_k . Kết quả đầu ra gồm:

- Ma trận tài liệu - chủ đề: Tỷ lệ của các chủ đề trong từng đánh giá.
- Ma trận chủ đề - từ vựng: Danh sách các từ khóa đại diện nhất cho từng chủ đề để người dùng dễ dàng hiểu được nội dung của nhóm đó.

2.5.3. So sánh K-Means và LDA trong thực nghiệm

Để chọn mô hình phù hợp cho hệ thống, Bảng 2.1 tóm tắt sự khác biệt giữa hai thuật toán dựa trên kết quả chạy thực nghiệm thực tế trên giao diện Streamlit:

Bảng 2.1: So sánh thực nghiệm đặc điểm K-Means và LDA

Tiêu chí	Thuật toán K-Means	Mô hình LDA
Thời gian xử lý	Dưới 1 giây (phản hồi ngay lập tức, rất mượt khi thao tác trên giao diện Dashboard).	Từ 3 đến 5 giây (có độ trễ khi tải dữ liệu mới hoặc thay đổi số chủ đề).
Ranh giới phân cụm	Phân cụm cứng: các đánh giá được phân tách rạch ròi, không chồng lấn.	Phân cụm mềm: mỗi đánh giá được phân bổ theo tỉ lệ phần trăm sang các chủ đề.
Từ khóa đặc trưng	Rất tập trung, các từ khóa trong cụm phản ánh rõ nét một chủ đề cụ thể.	Phong phú nhưng dễ bị lặp lại các từ khóa chung giữa các cụm khác nhau.
Loại văn bản phù hợp	Thích hợp với các đánh giá ngắn, phản ánh trực tiếp một nội dung duy nhất.	Phù hợp cho các đánh giá dài, thảo luận nhiều vấn đề cùng một lúc.
Ứng dụng thực tế	Giúp phân loại đánh giá trực tiếp để chuyển giao ngay đến các bộ phận xử lý chuyên trách.	Phù hợp để khai phá sâu nhằm nắm bắt bức tranh toàn cảnh về phản hồi của khách hàng.

Việc tích hợp cả hai thuật toán giúp người dùng linh hoạt lựa chọn phương pháp phù hợp nhất tùy thuộc vào yêu cầu phân tích và đặc điểm của tập dữ liệu đánh giá.

2.5.4. Giảm chiều dữ liệu và trực quan hóa cụm (Truncated SVD)

Dữ liệu văn bản sau khi vector hóa bằng TF-IDF sẽ có số chiều rất lớn, tương ứng với kích thước của tập từ vựng (hàng nghìn chiều). Mắt người không thể quan sát hoặc vẽ đồ thị biểu diễn dữ liệu trong không gian đa chiều này. Do đó, đồ án áp dụng kỹ thuật giảm chiều dữ liệu về không gian 2D để trực quan hóa các cụm chủ đề lên mặt phẳng.

Phương pháp được chọn là **Truncated SVD** (Singular Value Decomposition rút gọn) thay vì PCA thông thường. Vì ma trận TF-IDF chứa rất nhiều giá trị 0 (ma trận thưa), Truncated SVD có khả năng tính toán trực tiếp trên ma trận này mà không cần chuyển sang ma trận đặc, giúp ứng dụng chạy nhanh hơn và tiết kiệm bộ nhớ RAM khi xử lý lượng dữ liệu lớn.

Thuật toán phân tích ma trận đặc trưng ban đầu thành các thành phần và chỉ giữ lại 2 thành phần quan trọng nhất để tạo ra tọa độ 2D cho mỗi đánh giá. Biểu đồ phân tán (Scatter Plot) vẽ từ tọa độ này giúp người dùng quan sát trực quan chất lượng gom cụm: các đánh giá thuộc cùng

một nhóm (cùng màu) nếu tụ lại gần nhau và tách biệt với các nhóm khác thì chứng tỏ mô hình phân cụm hoạt động tốt.

3. Phương pháp thực hiện

3.1. Kiến trúc tổng thể của hệ thống

Để giải quyết bài toán gom cụm đánh giá và nhận diện cảnh báo khủng hoảng thương hiệu, hệ thống được thiết kế theo một luồng xử lý dữ liệu tuần tự. Kiến trúc tổng thể bao gồm hai module độc lập nhưng liên kết chặt chẽ: Module Huấn luyện mô hình (`train.py`) và Module Phân tích (`app.py`).

Đồ án chọn cách **tách biệt** khâu huấn luyện và khâu dự đoán để giao diện khởi động nhanh hơn và dễ dàng cập nhật mô hình sau này mà không làm gián đoạn hệ thống.

3.1.1. Module Huấn luyện mô hình (`train.py`)

Module này chịu trách nhiệm chuẩn bị bộ phân lớp cảm xúc cho hệ thống. Quy trình hoạt động gồm các bước:

1. **Đọc dữ liệu gán nhãn:** Tải tập CSV chứa đánh giá tiếng Việt đã được gán nhãn cảm xúc (`positive`, `negative`, `neutral`) từ nguồn dữ liệu (chi tiết xem Mục 4.2). Mỗi dòng bao gồm nội dung đánh giá (`comment`) và nhãn cảm xúc (`sentiment_label`).
2. **Tiền xử lý:** Áp dụng quy trình làm sạch giống hệt như module phân tích (xem Mục 3.3) để đảm bảo tính nhất quán giữa dữ liệu huấn luyện và dữ liệu dự đoán.
3. **Vector hóa TF-IDF:** Chuyển đổi văn bản thành ma trận đặc trưng. Bộ vector hóa (`TfidfVectorizer`) được cấu hình với:
 - `max_features = 5000`
 - `min_df = 2`
 - `gram_range = (1, 2)`
4. **Huấn luyện:** Thuật toán **Multinomial Naive Bayes** được huấn luyện trên ma trận TF-IDF và nhãn cảm xúc.
5. **Lưu trữ mô hình:** Cả mô hình Naive Bayes và đối tượng `TfidfVectorizer` được lưu thành các file nhị phân (`.pkl`) lưu trong thư mục `models/`. Việc lưu kèm `TfidfVectorizer`

là bắt buộc vì quá trình dự đoán cần sử dụng chính xác cùng một không gian đặc trưng với quá trình huấn luyện.

3.1.2. Module Phân tích (app.py)

Đây là giao diện Dashboard dành cho người dùng cuối, được xây dựng trên nền tảng Streamlit [8]. Luồng xử lý dữ liệu được thiết kế tuần tự theo sơ đồ sau:

1. **Nhập dữ liệu:** Hệ thống nhận luồng dữ liệu đánh giá từ file CSV được tải lên (chi tiết nguồn dữ liệu kiểm thử xem Mục 4.2). Bộ đọc hỗ trợ nhiều định dạng mã hóa (utf-8-sig, cp1258, latin1) để tương thích với nhiều nguồn dữ liệu tiếng Việt.
2. **Tiền xử lý NLP:** Áp dụng toàn bộ quy trình làm sạch, tách từ (Underthesea) và loại bỏ từ dừng (xem Mục 3.3).
3. **Dự đoán cảm xúc:** Hệ thống nạp các file mô hình .pkl đã lưu từ trước. Bước phân tích cảm xúc được thực hiện *trước* bước gom cụm. Mục đích là để hệ thống có thể lọc ra tập đánh giá “Tiêu cực” riêng biệt, từ đó chỉ tập trung khai phá và phát hiện bất thường trên tập dữ liệu rủi ro cao, giúp cảnh báo khủng hoảng chính xác hơn thay vì phân tích chung chung toàn bộ.
4. **Gom cụm chủ đề:** Dữ liệu văn bản được chuyển hóa thành ma trận TF-IDF mới (độc lập với bước Sentiment). Người dùng có thể chọn K-Means hoặc LDA trực tiếp trên giao diện.
5. **Tính điểm rủi ro và Phát hiện bất thường:** Kết hợp nhãn cảm xúc với các chỉ số tương tác để tính `comment_risk_score` (xem Mục 3.4). Áp dụng Moving Average trên chuỗi thời gian để phát hiện các ngày bùng phát khủng hoảng.
6. **Trực quan hóa:** Kết quả được trình bày thông qua biểu đồ Plotly [9], WordCloud, bảng dữ liệu tương tác và các chỉ số KPI trên Dashboard.

3.1.3. Các tham số cấu hình TF-IDF trên giao diện

Trong bước Gom cụm, bộ vector hóa TF-IDF được khởi tạo với bốn tham số mà người dùng có thể điều chỉnh trực tiếp trên thanh bên (sidebar) của Dashboard. Bảng 3.1 mô tả ý nghĩa và giá trị mặc định của từng tham số.

Bảng 3.1: Các tham số cấu hình TF-IDF trên giao diện

Tham số	Mặc định	Ý nghĩa
max_features	2500	Số lượng từ vựng tối đa được giữ lại khi xây dựng ma trận TF-IDF. Hệ thống chỉ chọn các từ có điểm TF-IDF cao nhất, giúp giảm chiều dữ liệu và tăng tốc xử lý.
min_df	2	Tần suất xuất hiện tối thiểu: một từ phải xuất hiện trong ít nhất 2 đánh giá mới được đưa vào từ điển. Tham số này lọc bỏ các từ hiếm, lỗi chính tả hoặc ký tự rác.
max_df	0.95	Ngưỡng loại bỏ từ quá phổ biến: các từ xuất hiện trong hơn 95% số đánh giá sẽ bị loại. Đây là cơ chế bổ sung cho danh sách từ dừng (stopwords), giúp loại các từ phổ biến nhưng không mang giá trị phân biệt cụm.
N-gram	(1, 2)	Phạm vi n-gram: hệ thống tính TF-IDF cho cả từ đơn (unigram) và cụm hai từ liên kề (bigram). Ví dụ: ngoài từ “giao” và “hàng” riêng lẻ, cụm “giao_hàng” cũng được xem là một đặc trưng, giúp bắt được ngữ cảnh tốt hơn.

Việc cho phép người dùng tùy chỉnh các tham số này giúp hệ thống linh hoạt hơn khi áp dụng với các bộ dữ liệu có đặc điểm khác nhau (ví dụ: dữ liệu ít đánh giá cần giảm min_df xuống 1, dữ liệu ngành chuyên biệt cần tăng max_features).

3.2. Lý do lựa chọn thuật toán

Đồ án ưu tiên sử dụng các thuật toán máy học truyền thống thay vì các mô hình Deep Learning (BERT, PhoBERT) hay mô hình ngôn ngữ lớn vì các lý do sau:

1. **Tốc độ xử lý:** Hệ thống được thiết kế để chạy trên máy tính cá nhân thông thường (không có GPU chuyên dụng). Các mô hình Transformer đòi hỏi phần cứng mạnh và thời gian suy diễn lâu hơn rất nhiều. Ngược lại, TF-IDF + K-Means/LDA + Naive Bayes cho kết quả gần như tức thời (dưới 5 giây cho hàng ngàn đánh giá), phù hợp với trải nghiệm người dùng trên Dashboard tương tác.
2. **Khả năng diễn giải:** TF-IDF cho phép trích xuất trực tiếp các từ khóa đặc trưng của từng cụm dưới dạng danh sách và WordCloud, giúp người phân tích hiểu rõ “cụm này nói về cái gì” mà không cần kiến thức chuyên sâu về học máy. Đây là ưu điểm lớn so với các biểu diễn embedding ẩn của Deep Learning vốn khó diễn giải.

3. **Tính thực tiễn trong môn học:** Đồ án tập trung vào việc ứng dụng các kỹ thuật Khai phá dữ liệu cổ điển (K-Means, LDA, Naive Bayes) – phù hợp với nội dung kiến thức của môn học – thay vì chạy theo các xu hướng công nghệ chưa nằm trong phạm vi đào tạo.

3.2.1. Sự phối hợp giữa Học có giám sát (Naive Bayes) và Học không giám sát (K-Means/LDA)

Hệ thống được thiết kế dựa trên sự kết hợp giữa hai phương pháp học máy: học có giám sát (supervised learning) và học không giám sát (unsupervised learning). Dù hoạt động độc lập, hai phương pháp này hỗ trợ lẫn nhau rất tốt trong việc phát hiện khủng hoảng.

- **Độc lập về mặt thuật toán:** Mô hình Naive Bayes phân loại cảm xúc (được huấn luyện trước trong file `train.py`) và các thuật toán gom cụm K-Means/LDA (được chạy trực tiếp trong `app.py`) không phụ thuộc vào nhau. Việc huấn luyện Naive Bayes không cần biết đến các cụm chủ đề, và ngược lại, K-Means hay LDA cũng không cần dùng đến nhãn cảm xúc để gom cụm. Điều này giúp dễ dàng thay đổi hoặc nâng cấp từng phần (chẳng hạn như dùng thuật toán khác thay cho Naive Bayes mà không ảnh hưởng đến phần gom cụm).
- **Hỗ trợ lẫn nhau trong ứng dụng:** Dù tính toán độc lập, hai thuật toán này lại được ghép nối thành một quy trình hoàn chỉnh:
 1. **Lọc bình luận tiêu cực (Học có giám sát):** Đầu tiên, mô hình Naive Bayes sẽ quét qua tất cả dữ liệu đánh giá của khách hàng để tìm và tách riêng các bình luận mang cảm xúc tiêu cực (*negative*). Đây là nhóm dữ liệu có rủi ro cao nhất và cần được tập trung phân tích.
 2. **Tìm hiểu nguyên nhân (Học không giám sát):** Sau khi có được danh sách bình luận tiêu cực, hệ thống mới áp dụng thuật toán gom cụm (K-Means/LDA) lên tập dữ liệu này. Thay vì chỉ báo cáo chung chung là có nhiều ý kiến chê bai, việc gom cụm sẽ giúp tự động phân nhóm các bình luận thành những chủ đề cụ thể (như lỗi sản phẩm, giao hàng chậm, thái độ nhân viên...).

Nhờ sự kết hợp này, hệ thống không chỉ dừng lại ở việc thống kê cảm xúc mà còn giúp hiểu rõ nguyên nhân cốt lõi khiến khách hàng không hài lòng. Qua đó, người sử dụng có thể nhanh chóng nhận biết có rủi ro xảy ra (thông qua Naive Bayes và Moving Average) và biết được vấn đề cụ thể đang nằm ở đâu (thông qua K-Means/LDA) để đưa ra hướng giải quyết.

3.3. Quy trình tiền xử lý chi tiết

Cả hai module (`train.py` và `app.py`) đều sử dụng chung một quy trình tiền xử lý nhất quán, được triển khai qua hai hàm cốt lõi: `clean_text()` và `remove_stopwords()`. Chi tiết quy trình:

1. **Chuyển chữ thường:** Đồng nhất hóa dữ liệu, tránh trùng lặp đặc trưng do hoa/thường.
2. **Loại bỏ URL và Email:** Sử dụng Regex `http\S+|www\.\S+` và `\S+@\S+`.
3. **Loại bỏ mention và hashtag:** Regex `[@#]\w+`.
4. **Loại bỏ số:** Regex `\d+`. Lý do: Số (năm, giá tiền, SĐT) không mang ngữ nghĩa khi gom cụm chủ đề.
5. **Loại bỏ ký tự đặc biệt:** Chỉ giữ lại ký tự chữ cái (bao gồm ký tự tiếng Việt có dấu ã-ỹ).
6. **Tách từ tiếng Việt:** Gọi `word_tokenize(text, format="text")` từ Underthesea.
7. **Loại bỏ từ dừng:** Lọc theo danh sách hơn 80 từ dừng tiếng Việt và một số từ tiếng Anh phổ biến.
8. **Loại bỏ từ ngắn:** Xóa các token có độ dài ≤ 1 ký tự.

Quy trình này đảm bảo dữ liệu đầu vào cho các thuật toán khai phá là các chuỗi từ tiếng Việt đã được chuẩn hóa, giảm tối đa nhiễu và tăng chất lượng đặc trưng TF-IDF.

3.4. Công thức đánh giá Rủi ro khủng hoảng

Thay vì chỉ đếm số lượng đánh giá tiêu cực, đồ án sử dụng một chỉ số gọi là `comment_risk_score` (điểm rủi ro) để đánh giá mức độ nguy hiểm của từng đánh giá dựa trên ba yếu tố:

3.4.1. Cấu thành công thức

Điểm rủi ro tổng hợp cho mỗi đánh giá i được tính theo công thức:

$$R_i = S_i \times 45 + T_i \times 18 + \min(E_i \times 4, 35) \quad (3.1)$$

trong đó:

- $S_i \in \{0, 1\}$: Cờ nhị phân cho biết đánh giá có được phân lớp là “Tiêu cực” hay không. Nếu đánh giá mang cảm xúc tiêu cực, nó tự động nhận được 45 điểm rủi ro cơ sở.
- T_i : Số lượng từ khóa khủng hoảng tìm thấy trong nội dung đánh giá. Các từ khóa này nằm trong một danh sách được định nghĩa trước, bao gồm các thuật ngữ như: “tẩy chay”, “lừa đảo”, “hoàn tiền”, “lỗi hệ thống”. Mỗi từ khóa khủng hoảng xuất hiện được cộng thêm 18 điểm rủi ro.
- E_i : Chỉ số lan truyền, được tính qua biến đổi logarit để triệt tiêu ảnh hưởng của các đánh giá có số tương tác cực lớn:

$$E_i = \ln(1 + \text{likes}_i) + 1.5 \times \ln(1 + \text{shares}_i) \quad (3.2)$$

Hàm $\ln(1 + x)$ (tức $\log_{1p}$) đảm bảo rằng khi engagement bằng 0 thì $E_i = 0$, và khi engagement tăng lớn thì điểm tăng chậm dần. Hệ số 1.5 cho lượt chia sẻ phản ánh thực tế rằng việc chia sẻ có sức lan tỏa lớn hơn lượt thích. Giá trị $E_i \times 4$ bị giới hạn tối đa 35 để tránh thành phần engagement “lấn át” các yếu tố khác.

Điểm rủi ro cuối cùng được giới hạn trong khoảng $[0, 100]$ và phân loại thành 4 mức:

- $R_i \geq 75$: **Rất cao** – Cần xử lý khẩn cấp.
- $55 \leq R_i < 75$: **Cao** – Cần theo dõi sát.
- $30 \leq R_i < 55$: **Trung bình** – Cần lưu ý.
- $R_i < 30$: **Thấp** – Ít khả năng gây khủng hoảng.

3.4.2. Phát hiện bất thường bằng Đường trung bình động

Sau khi tính điểm rủi ro cho từng đánh giá, hệ thống nhóm dữ liệu theo trục thời gian (theo ngày) và đếm số lượng đánh giá tiêu cực mỗi ngày. Một **đường trung bình động** (Moving Average) với kích thước cửa sổ trượt w ngày được tính:

$$MA_t = \frac{1}{w} \sum_{i=t-w}^{t-1} N_i \quad (3.3)$$

trong đó N_i là số đánh giá tiêu cực tại ngày thứ i , MA_t là giá trị trung bình động tính đến ngày t (không bao gồm ngày t , vì ta cần so sánh ngày hiện tại với xu hướng quá khứ).

Một ngày t được đánh dấu là **bùng phát khủng hoảng** nếu thỏa hai điều kiện:

$$N_t > MA_t \times \alpha \quad \text{và} \quad N_t \geq 3 \quad (3.4)$$

trong đó α là **hệ số đột biến** do người dùng thiết lập trên giao diện. Điều kiện thứ hai ($N_t \geq 3$) là bộ lọc nhiễu, tránh cảnh báo sai cho những ngày có rất ít đánh giá nhưng tỷ lệ tiêu cực cao (ví dụ: 1 ngày chỉ có 2 đánh giá, cả 2 đều tiêu cực).

Việc cho phép người dùng điều chỉnh hai tham số w và α giúp hệ thống linh hoạt hơn tùy theo từng đợt truyền thông. Bảng 3.2 mô tả ý nghĩa và giá trị mặc định của từng tham số.

Bảng 3.2: Các tham số cấu hình cảnh báo khủng hoảng trên giao diện

Tham số	Mặc định	Ý nghĩa
Số ngày tính trung bình (w)	7	Kích thước cửa sổ trượt dùng để tính đường trung bình động. Giá trị $w = 7$ nghĩa là hệ thống lấy trung bình số đánh giá tiêu cực trong 7 ngày trước đó làm đường nền so sánh. Giá trị nhỏ hơn giúp phát hiện nhanh nhưng dễ nhiễu, giá trị lớn hơn cho đường nền ổn định hơn.
Hệ số đột biến (α)	2.0	Hệ số nhân với đường trung bình động để xác định ngưỡng cảnh báo. Với $\alpha = 2.0$, một ngày chỉ bị đánh dấu là bùng phát khi số đánh giá tiêu cực vượt gấp đôi mức trung bình. Tăng α giúp giảm cảnh báo sai nhưng có thể bỏ sót; giảm α giúp phát hiện nhạy hơn nhưng dễ báo động nhầm.

3.5. Định dạng Bộ dữ liệu đầu vào

Để các thuật toán trên có thể vận hành, hệ thống yêu cầu cấu trúc dữ liệu tối thiểu gồm:

- **comment_text** (Bắt buộc): Nội dung đánh giá phi cấu trúc, là đầu vào chính cho toàn bộ quy trình khai phá NLP.
- **created_at** (Tùy chọn nhưng quan trọng): Thời gian đăng đánh giá. Đây là trục tham chiếu bắt buộc để vẽ biểu đồ chuỗi thời gian và tính toán Moving Average (xem Mục 3.4.2).
- **likes, shares** (Tùy chọn): Lượt tương tác, làm trọng số cho thành phần E_i trong công thức `comment_risk_score` (xem Công thức 3.2).

- **platform** (Tùy chọn): Nền tảng/kênh (Facebook, Shopee, Tiktok...), hỗ trợ phân tích nguồn gây khủng hoảng theo từng kênh.

Nếu tập dữ liệu thiếu các cột không bắt buộc (như `created_at`), hệ thống sẽ bỏ qua phần biểu đồ thời gian nhưng vẫn chạy được các chức năng phân tích và gom cụm. Điều này giúp ứng dụng dễ dàng tiếp nhận nhiều định dạng dữ liệu khác nhau.

4. Thực nghiệm và Đánh giá

4.1. Môi trường và Công cụ phát triển

Hệ thống được phát triển và kiểm thử trên môi trường với cấu hình như sau:

Bảng 4.1: Cấu hình môi trường phát triển

Thành phần	Chi tiết
Ngôn ngữ lập trình	Python 3.10+
Thư viện NLP	underthesea (Tách từ tiếng Việt), re (Biểu thức chính quy)
Thư viện học máy	scikit-learn (TF-IDF, K-Means, LDA, Multinomial NB, Silhouette Score)
Thư viện trực quan hóa	matplotlib, plotly, wordcloud
Framework giao diện	streamlit – Dashboard phân tích tương tác [8]
Serialization	pickle (Lưu model và vectorizer dạng .pkl)

Toàn bộ mã nguồn được tổ chức theo cấu trúc thư mục rõ ràng:

- `train.py`: Script huấn luyện mô hình Sentiment.
- `app.py`: Ứng dụng Streamlit chính.
- `models/`: Chứa các file mô hình đã huấn luyện bao gồm:
 - `sentiment_model.pkl`
 - `tfidf_vectorizer_nb.pkl`
- `data/`: Chứa bộ dữ liệu mẫu tiếng Việt.

4.2. Bộ dữ liệu thực nghiệm

Hệ thống được thực nghiệm và phát triển dựa trên ba bộ dữ liệu chính: hai bộ dữ liệu để huấn luyện mô hình và một bộ dữ liệu để kiểm thử (test) hệ thống phân tích.

Cụ thể, đối với quá trình huấn luyện mô hình học máy (thông qua `train.py`), hệ thống sử dụng hai bộ dữ liệu từ cộng đồng Kaggle:

- **Vietnamese Sentiment Analyst Data [10]**: Tập dữ liệu `train_vietnamese_sentiment_analyst_c` bao gồm các văn bản tiếng Việt đã được gán nhãn cảm xúc.

- **Sentiment Classification Vietnamese Comment [11]:** Tập dữ liệu `train_shop_vietnamese_text` chứa các bình luận đánh giá sản phẩm mua sắm bằng tiếng Việt.

Đối với quá trình phân tích trực tuyến và kiểm thử hệ thống (Dashboard):

- **Dữ liệu tự tổng hợp:** Bộ dữ liệu `test_vietnamese_social_comments_large.csv` được sử dụng để kiểm thử. Đây là bộ dữ liệu do nhóm tự thu thập, chỉnh sửa và phát sinh tự động (generate), mô phỏng các đánh giá từ nhiều nền tảng thương mại điện tử và mạng xã hội. Dữ liệu gồm các trường thông tin: nội dung đánh giá (comment), nhãn cảm xúc (sentiment_label), thời gian đăng (date), lượt thích (likes), lượt chia sẻ (shares) và nền tảng (platform).

Các bộ dữ liệu huấn luyện được dùng để huấn luyện mô hình Naive Bayes phân lớp cảm xúc, trong khi bộ dữ liệu kiểm thử được tải trực tiếp lên Dashboard để thực hiện mô phỏng phân tích, gom cụm chủ đề và phát hiện thời điểm khủng hoảng mạng xã hội.


4.3. Kết quả Phân tích cảm xúc

4.3.1. Huấn luyện mô hình Naive Bayes


Mô hình Multinomial Naive Bayes được huấn luyện theo quy trình mô tả tại Mục 3.1.1. Bộ vector hóa TF-IDF được cấu hình với `max_features=5000` và `ngram_range=(1,2)`, cho phép mô hình học được cả từ đơn lẫn cụm hai từ để tăng khả năng nhận diện ngữ cảnh. Kết quả đánh giá trên tập huấn luyện cho thấy mô hình phân lớp ba nhãn (Tích cực, Tiêu cực, Trung lập) với hiệu suất chấp nhận được.

4.3.2. Kết quả dự đoán trên Dashboard

Sau khi nạp mô hình đã huấn luyện, hệ thống thực hiện dự đoán cảm xúc cho từng đánh giá trong tập dữ liệu phân tích. Kết quả được trình bày qua biểu đồ phân bố cảm xúc dạng cột (Hình 4.1) và dạng biểu đồ tròn biểu diễn tỷ lệ phần trăm (Hình 4.2).



Hình 4.1: Biểu đồ cột phân bố cảm xúc đánh giá sau khi dự đoán bằng Naive Bayes




Hình 4.2: Biểu đồ tròn tỷ lệ phần trăm phân bố cảm xúc đánh giá sau khi dự đoán bằng Naive Bayes

Biểu đồ cho phép người phân tích nhanh chóng nắm được tỷ lệ đánh giá tích cực, trung lập và tiêu cực trong toàn bộ tập dữ liệu. Tỷ lệ đánh giá tiêu cực là chỉ số đầu tiên để đánh giá mức độ “sức khỏe thương hiệu”. Ngoài ra, Dashboard cũng trích xuất bảng **Top từ khóa TF-IDF trong đánh giá tiêu cực**, giúp nhanh chóng xác định vấn đề cụ thể mà khách hàng đang phàn nàn (ví dụ: “giao_hàng”, “hỗ_trợ”, “lỗi_thanh_toán”).

4.4. Kết quả Gom cụm chủ đề

4.4.1. Tối ưu hóa số lượng cụm bằng Elbow Method

Đối với thuật toán K-Means, hệ thống tích hợp tính năng tự động tính và vẽ đồ thị Elbow, hiển thị giá trị hàm mục tiêu WCSS (xem Công thức 2.8) theo các giá trị K từ 2 đến 10.



Hình 4.3: Đồ thị phương pháp Elbow: Giá trị WCSS theo số cụm K

Cách đọc đồ thị: Trên đồ thị Elbow (Hình 4.3), giá trị WCSS luôn giảm khi K tăng (vì chia nhiều cụm hơn tất yếu làm giảm khoảng cách nội cụm). Tuy nhiên, tại một giá trị K nhất định, tốc độ giảm sẽ chậm lại rõ rệt – tạo thành điểm “cùi chỏ”. Đây là giá trị K tối ưu, cân bằng giữa việc chia quá ít cụm (thông tin chưa tách rõ) và quá nhiều cụm (phức tạp không cần thiết). Tính năng “Tự động chọn K tối ưu” của ứng dụng sẽ tự động tìm điểm Elbow bằng cách tính khoảng cách từ các điểm trên đường cong tới đường thẳng nối hai điểm đầu cuối. Tuy nhiên, người dùng vẫn có thể tự quan sát đồ thị và chọn lại K thông qua thanh trượt trên giao diện.

Ngoài ra, đối với K-Means, hệ thống còn tính **Silhouette Score** – chỉ số đo chất lượng gom cụm trong khoảng $[-1, 1]$. Giá trị càng gần 1 cho thấy các cụm tách biệt rõ ràng, giá trị gần 0 cho thấy các cụm chồng lấn nhiều.

4.4.2. Trực quan hóa kết quả gom cụm

Sau khi gom cụm (bằng K-Means hoặc LDA), mỗi cụm được đại diện bởi **Top 10 từ khóa** có chỉ số TF-IDF cao nhất. Hệ thống tự động sinh mây từ vựng (**WordCloud**) cho mỗi cụm,


trong đó kích thước của từ tỷ lệ thuận với trọng số TF-IDF, giúp người dùng nhanh chóng nhận biết chủ đề chính của từng cụm chỉ bằng một cái nhìn.




Hình 4.4: Mây từ vựng đại diện cho các cụm chủ đề

Bên cạnh mây từ vựng, hệ thống còn cung cấp:

- **Biểu đồ cột** thống kê số lượng đánh giá thuộc mỗi cụm (Hình 4.5).
- **Biểu đồ phân tán 2D** sau khi giảm chiều bằng SVD (Hình 4.6), giúp quan sát trực quan sự phân bố và ranh giới giữa các cụm.
- **Danh sách đánh giá mẫu** cho mỗi cụm, kèm theo nhãn cảm xúc và điểm rủi ro, giúp người dùng đối chiếu nội dung chi tiết.



Hình 4.5: Biểu đồ cột thống kê số lượng đánh giá theo từng cụm chủ đề K-Means



Hình 4.6: Trực quan hóa không gian các cụm đánh giá bằng phương pháp Truncated SVD

4.4.3. So sánh định tính giữa K-Means và LDA

Ứng dụng cho phép so sánh trực tiếp kết quả giữa K-Means và LDA trên cùng một bộ dữ liệu. Người dùng có thể dễ dàng chuyển đổi qua lại giữa hai thuật toán trên thanh cầu hình.



WordCloud từ K-Means



WordCloud từ LDA

Hình 4.7: So sánh trực quan kết quả gom cụm giữa K-Means và LDA

Thông qua việc so sánh mây từ vựng và danh sách từ khóa của hai phương pháp, có thể rút ra một số nhận xét:

- **K-Means** có xu hướng tạo ra các cụm có ranh giới rõ ràng hơn vì mỗi đánh giá chỉ thuộc đúng một cụm. Tuy nhiên, nếu một đánh giá đề cập đến nhiều chủ đề, K-Means buộc phải “chọn” một cụm duy nhất, có thể dẫn đến mất thông tin.

- **LDA** cho phép một đánh giá thuộc nhiều chủ đề (gom cụm mềm), phản ánh tự nhiên hơn đặc điểm của dữ liệu văn bản thực tế. Tuy nhiên, các chủ đề từ LDA đôi khi có sự chồng lấn từ khóa giữa các cụm.
- Sự lựa chọn giữa hai phương pháp phụ thuộc vào mục đích phân tích: nếu cần phân tách rõ ràng để xử lý từng nhóm vấn đề riêng biệt, K-Means là lựa chọn tốt hơn; nếu cần khám phá cấu trúc chủ đề tiềm ẩn và cho phép sự đa dạng, LDA phù hợp hơn.


4.5. Kết quả Theo dõi và Cảnh báo Khủng hoảng

Tính năng quan trọng nhất của hệ thống là theo dõi diễn biến đánh giá tiêu cực theo chuỗi thời gian và phát hiện tự động các ngày bùng phát bất thường.

4.5.1. Biểu đồ chuỗi thời gian tương tác

Hệ thống sử dụng thư viện Plotly [9] để vẽ biểu đồ chuỗi thời gian tương tác gồm bốn lớp thông tin:

1. **Đường tổng đánh giá** (màu xám, nét đứt): Cho thấy tổng quan hoạt động đánh giá theo thời gian.
2. **Đường đánh giá tiêu cực** (màu đỏ, nét liền): Số lượng đánh giá được phân lớp là “Tiêu cực” mỗi ngày.
3. **Đường trung bình động** (MA, màu vàng, nét chấm): Giá trị MA tính theo công thức (3.3) với tham số Window Size do người dùng cấu hình.
4. **Điểm bùng phát** (Anomaly, biểu tượng ngôi sao đỏ): Các ngày thỏa điều kiện cảnh báo theo công thức (3.4).



Hình 4.8: Biểu đồ chuỗi thời gian: Diễn biến đánh giá tiêu cực và cảnh báo bùng phát

4.5.2. Vai trò của các tham số điều chỉnh

Hai tham số quan trọng được trao cho người dùng điều chỉnh trên giao diện:

- **Window Size** (w , mặc định = 7 ngày): Số ngày dùng để tính trung bình động. Giá trị w nhỏ (3–5 ngày) giúp phát hiện các đợt bùng phát ngắn hạn, giá trị w lớn (10–14 ngày) phù hợp cho xu hướng dài hạn.
- **Threshold Multiplier** (α , mặc định = 2.0): Hệ số nhân với đường MA để xác định ngưỡng cảnh báo. Giá trị α thấp (1.5x) tạo ra nhiều cảnh báo hơn (độ nhạy cao, nhưng có thể nhiều cảnh báo sai); giá trị α cao (3.0x–5.0x) chỉ cảnh báo khi bùng phát thực sự nghiêm trọng.

Điều này giúp người quản trị dễ dàng tùy chỉnh theo tình hình thực tế. Biểu đồ Plotly cũng cho phép phóng to, thu nhỏ và di chuột để xem chi tiết thời gian cùng số lượng đánh giá tại các điểm bùng phát.

4.5.3. Phân tích nguồn gây khủng hoảng theo kênh

Nếu dữ liệu có cột nền tảng (platform), hệ thống tự động nhóm và so sánh các chỉ số khủng hoảng giữa các kênh truyền thông khác nhau (Facebook, Shopee, Tiktok...). Bảng phân tích hiển thị: tổng đánh giá, số đánh giá tiêu cực, tỷ lệ tiêu cực (%), và điểm rủi ro trung bình cho mỗi kênh. Thông tin này giúp quản trị viên xác định kênh nào đang là “tâm bão” của khủng hoảng để ưu tiên xử lý.

5. Kết luận

5.1. Kết quả đạt được

Thông qua quá trình thực hiện đề án môn Khai phá dữ liệu và Truyền thông xã hội, nhóm đã hoàn thành việc xây dựng **“Xây dựng hệ thống phân tích và gom cụm đánh giá trực tuyến nhằm cảnh báo khủng hoảng thương hiệu”**. Đối chiếu với các mục tiêu đã đề ra, hệ thống đạt được các kết quả sau:

1. **Về tiền xử lý và biểu diễn dữ liệu:** Cài đặt quy trình tiền xử lý văn bản tiếng Việt, sử dụng thư viện `underthesea` để tách từ và xây dựng bộ từ dừng tùy chỉnh. Dữ liệu văn bản được biểu diễn thành các vector đặc trưng thông qua mô hình TF-IDF.
2. **Về gom cụm chủ đề:** Hệ thống cung cấp hai thuật toán K-Means và LDA để người dùng so sánh. K-Means được tích hợp phương pháp Elbow để hỗ trợ chọn số cụm K phù hợp. Kết quả gom cụm được trực quan hóa bằng WordCloud và biểu đồ phân tán.
3. **Về phân loại cảm xúc:** Mô hình Multinomial Naive Bayes được huấn luyện và lưu lại dưới dạng file `.pkl` để phân loại nhanh các đánh giá thành ba nhóm: Tích cực, Tiêu cực, Trung lập.
4. **Về cảnh báo khủng hoảng:** Hệ thống đưa ra điểm số rủi ro `comment_risk_score` dựa trên cảm xúc, từ khóa và tương tác. Sử dụng đường trung bình động để phát hiện và cảnh báo những thời điểm đánh giá tiêu cực tăng đột biến.
5. **Về giao diện:** Ứng dụng web được xây dựng bằng Streamlit với các chức năng báo cáo, phân tích và xem dữ liệu để người dùng dễ thao tác.

5.2. Hạn chế của hệ thống

Trong quá trình thực hiện, đề án vẫn còn một số điểm hạn chế:

- **Nguồn dữ liệu:** Ứng dụng hiện tại chỉ xử lý dữ liệu từ tệp CSV có sẵn, chưa có khả năng thu thập dữ liệu tự động từ các nền tảng thương mại điện tử.

- **Giới hạn của thuật toán:** Thuật toán Multinomial Naive Bayes chưa xử lý tốt các đánh giá có cấu trúc câu phức tạp, sử dụng từ lóng hoặc mang ý nghĩa mỉa mai do đặc điểm của phương pháp Bag-of-Words.
- **Khả năng xử lý dữ liệu lớn:** Mô hình TF-IDF tạo ra ma trận có kích thước lớn khi tập từ vựng tăng lên. Điều này có thể làm giảm hiệu suất xử lý nếu dữ liệu đầu vào quá lớn.
- **Đánh giá mô hình:** Việc đánh giá mô hình phân loại cảm xúc hiện chỉ được thực hiện trên tập dữ liệu nhỏ và chưa áp dụng các kỹ thuật như Cross-Validation để kiểm chứng độ ổn định.

5.3. Hướng phát triển

Từ những kết quả và hạn chế trên, nhóm đưa ra một số hướng phát triển cho đề tài:

1. **Thu thập dữ liệu tự động:** Tích hợp các công cụ thu thập dữ liệu hoặc kết nối qua API của các nền tảng thương mại điện tử để phân tích luồng thông tin liên tục.
2. **Sử dụng mô hình học sâu:** Thay thế TF-IDF và Naive Bayes bằng các mô hình ngôn ngữ lớn như PhoBERT [12] để cải thiện độ chính xác trong việc hiểu ngữ cảnh và cảm xúc đánh giá tiếng Việt.
3. **Phát hiện chủ đề theo thời gian:** Cải thiện thuật toán để có thể theo dõi sự thay đổi của các chủ đề thảo luận qua từng mốc thời gian khác nhau.
4. **Nâng cấp hệ thống cảnh báo:** Gửi thông báo trực tiếp qua email hoặc ứng dụng nhắn tin khi hệ thống phát hiện dấu hiệu khủng hoảng.
5. **Đánh giá định lượng:** Thực hiện đánh giá chi tiết hơn với các chỉ số như Precision, Recall, F1-Score trên các tập dữ liệu đa dạng hơn.

5.4. Kết luận chung

Đồ án đã trình bày quy trình xây dựng một hệ thống phân tích văn bản kết hợp các kỹ thuật gom cụm bằng K-Means, LDA, phân loại với Naive Bayes và phát hiện bất thường dựa trên đường trung bình động. Ứng dụng giúp tự động hóa quá trình phân tích đánh giá tiếng Việt và hỗ trợ đưa ra các cảnh báo về khủng hoảng thương hiệu. Mặc dù vẫn còn những mặt hạn chế,

kết quả của đồ án cho thấy khả năng ứng dụng các thuật toán máy học truyền thống vào việc phân tích và giám sát ý kiến người dùng trên các nền tảng thương mại điện tử.

Tài liệu tham khảo


- [1] Daniel Jurafsky and James H Martin. *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*. Draft, 3rd edition, 2023.
- [2] Jiawei Han, Jian Pei, and Micheline Kamber. *Data Mining: Concepts and Techniques*. Morgan Kaufmann, 3rd edition, 2011.
- [3] Vu Anh. Underthesea: Vietnamese natural language processing toolkit. <https://github.com/undertheseanlp/underthesea>, 2018. Truy cập: 15/05/2026.
- [4] Gerard Salton and Christopher Buckley. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5):513–523, 1988.
- [5] Andrew McCallum, Kamal Nigam, et al. A comparison of event models for naive bayes text classification. In *AAAI-98 Workshop on Learning for Text Categorization*, volume 752, pages 41–48. Citeseer, 1998.
- [6] James MacQueen et al. Some methods for classification and analysis of multivariate observations. *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, 1(14):281–297, 1967.
- [7] David M Blei, Andrew Y Ng, and Michael I Jordan. Latent dirichlet allocation. *Journal of Machine Learning Research*, 3(Jan):993–1022, 2003.
- [8] Streamlit Inc. Streamlit: The fastest way to build and share data apps. <https://streamlit.io/>, 2024. Truy cập: 15/05/2026.
- [9] Plotly Technologies Inc. Plotly: The front end for ml and data science models. <https://plotly.com/python/>, 2024. Truy cập: 15/05/2026.
- [10] linhlpv. Vietnamese sentiment analyst data. <https://www.kaggle.com/datasets/linhlpv/vietnamese-sentiment-analyst>, 2024. Kaggle Dataset.
- [11] dingggggg. Sentiment classification vietnamese comment. <https://www.kaggle.com/code/dingggggg/sentiment-classification-vietnamese-comment/input?select=train.csv>, 2024. Kaggle Dataset.

- [12] Dat Quoc Nguyen and Anh Tuan Nguyen. PhoBERT: Pre-trained language models for Vietnamese. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 1037–1042, 2020.
- [13] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [14] Christopher D Manning, Prabhakar Raghavan, and Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- [15] Bing Liu. Sentiment analysis and opinion mining. *Synthesis Lectures on Human Language Technologies*, 5(1):1–167, 2012.
- [16] Varun Chandola, Arindam Banerjee, and Vipin Kumar. Anomaly detection: A survey. *ACM Computing Surveys*, 41(3):1–58, 2009.
- [17] Andreas C. Mueller. word_cloud: A little word cloud generator in Python. https://github.com/amueller/word_cloud, 2023. Truy cập: 15/05/2026.

A. Phụ lục hình ảnh

Phần này cung cấp các hình ảnh trực quan về giao diện của hệ thống **Phân tích và Gom cụm Đánh giá trực tuyến nhằm Cảnh báo Khủng hoảng Thương hiệu** được xây dựng bằng framework Streamlit, minh họa cho các quy trình phân tích đã trình bày trong báo cáo.

A.1. Giao diện tổng quan và cấu hình hệ thống



Hình A.1: Giao diện Dashboard tổng quan sau khi nạp dữ liệu thành công. Bảng điều khiển (Sidebar) cho phép cấu hình tham số K-Means/LDA, chọn cột thời gian, nền tảng và ngưỡng cảnh báo khủng hoảng.

▼ Tham số gom cụm

Thuật toán

☒ K-Means


☐ LDA

☒ Tự động chọn K tối ưu (phương pháp Elbow)

Hệ thống sẽ tự động tìm K tối ưu dựa trên phương pháp Elbow.


Đặc trưng tối đa (max_features)

2500




Tần suất xuất hiện tối thiểu (min_df)

2



Loại bỏ từ quá phổ biến (max_df)


0.95




Cấu hình N-gram

☐ 1-gram


A.2. Giao diện phân tích và cảnh báo chuyên sâu



Hình A.3: Kết quả phân tích cảm xúc đánh giá bằng mô hình Naive Bayes, hiển thị thống kê tổng quan và chỉ số rủi ro (Risk Score).



Hình A.4: Đồ thị Elbow tối ưu hóa K tự động: Hệ thống đánh dấu điểm cùi chỏ (ngôi sao đỏ) bằng thuật toán nội suy khoảng cách lớn nhất.



Ứng dụng học thuật: Phân tích NLP (underthesesa, TF-IDF), K-means/LDA, Naive Bayes Sentiment, Anomaly Detection.

Phân tích hoàn tất.

Tóm tắt Thuật toán

Thuật toán

Số cụm đã tạo

5

Số đặc trưng (Từ khóa)

2,500

Silhouette score

0.030

Tổng quan khủng hoảng

Đánh giá tiêu cực

Đánh giá trung lập

Đánh giá tích cực

Đánh giá rủi ro cao

Chi số khủng hoảng

1,593
↑ 47.4%

819


952

1,57
↑ 46.7%

94.6/100

↑ Rất cao

Phân bố cảm xúc



Top từ khóa trong đánh giá tiêu cực

	Từ khóa	Điểm TF-IDF
3	những	36.3
4	phần_hỏi	33.1
5	app	32.8
6	bức_xúc	32.6
7	trải_nghịm	27.7
8	học_phi	28.9
9	đang	28.5
10	hệ_thống	28.5
11	lần	28.1

Timeline cảnh báo đột biến (Có 1 ngày)

Phát hiện 1 ngày có lượng đánh giá tiêu cực tăng vọt so với trung bình (7 ngày trước, hệ số 2.0x).

Diễn biến đánh giá tiêu cực & Cảnh báo đột biến



Phân tích nguồn gây khủng hoảng (Theo kênh/nền tảng)

	platform	long_tiret_suan	birth_suan_tiret_cuc	drem_nut_re_tb	ty_re_tiret_cuc_%	
2	Lazada	584	300	\$4.5	51	
1	Instagram	596	283	\$1	47	
5	YouTube	553	260	\$0.6	4	
4	TikTok	544	252	\$1.2	46	
3	Shopee	538	249	\$0.5	45	
0	Facebook	549	249	\$0.2	46	

Danh sách đánh giá có nguy cơ khủng hoảng cao

	date	platform	comment	sentiment_v1	cluster_name	crisis_terms	comment_id
3283	2026-04-26	Shopee	Nhà phân phối thứ 2 đã bị hại, hỗ trợ học viên và trách nhiệm. Sợ đến già, không đi	Tiêu cực	Cym 4-tiền, không bán, bề, quan tâm	vô trách nhiệm, tệ nhất	
3270	2026-03-27	Facebook	Gửi nhân viên Topica đã cũ tuần mà Giao hàng đi kèm in tình bằng giấy quỳ, có thể	Tiêu cực	Cym 4-tiền, không bán, bề, quan tâm	có, thường xuyên	
3263	2026-05-06	YouTube	Hàng nhân viên Topica đã cũ tuần mà Giao hàng đi kèm in tình bằng giấy quỳ, có thể	Tiêu cực	Cym 4-tiền, không bán, bề, quan tâm	lừa đảo, né tránh	
2960	2026-06-05	Instagram	LÀO BẢO CHỨNG không học phí khi bị lừa đảo của Vinchroom làm học viên bị tổn	Tiêu cực	Cym 4-tiền, không bán, bề, quan tâm	lừa đảo, bóc lột, cáo	
2966	2026-06-05	Lazada	VỠ TRÁCH NHIỆM Vinchroom Lừa đảo không học phí khi học viên xin rút học	Tiêu cực	Cym 4-tiền, không bán, bề, quan tâm	lừa đảo, vô trách nhiệm	
2786	2026-05-21	TikTok	TRAI CHAM Tái về Grab lại về cực độ, lang lang phóng nhảm, thì đi về chỉ cần	Lừa	Cym 4-tiền, không bán, bề, quan tâm	lừa, chây	
2789	2026-05-21	Facebook	Tái về Grab lại về cực độ, lang lang phóng nhảm, thì đi về chỉ cần	Tiêu cực	Cym 4-tiền, không bán, bề, quan tâm	lừa, chây	
3150	2026-04-02	Lazada	Quên ý ZaliFox có thường kích hàng, thì đi về chỉ cần	Tiêu cực	Cym 4-tiền, không bán, bề, quan tâm	vô trách nhiệm, khiếu nại	
3267	2026-04-02	Lazada	CSKH ZaliFox lại về vấn đề, vô trách nhiệm trên trình gửi quỳ khiếu nại	Tiêu cực	Cym 4-tiền, không bán, bề, quan tâm	vô trách nhiệm, khiếu nại	
2423	2026-06-03	Facebook	Bị lừa thanh toán mất tiền trên app, khiếu nại mãi không được tiền. Quá bóc	Tiêu cực	Cym 4-tiền, không bán, bề, quan tâm	hàn, tiền, bóc lột, khiếu nại	

45