

**ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN**



**PHÂN TÍCH THĂM DÒ DIAMONDS DATASET VÀ
DỰ ĐOÁN GIÁ KIM CƯƠNG (PANDAS, SCIKIT-
LEARN; HỒI QUY TUYẾN TÍNH/ĐA THỨC)**

Nhóm 07			
Sinh viên thực hiện:			
STT	Họ tên	MSSV	Ngành
1	Lê Hải Phúc	23730116	CNTT

TP. HỒ CHÍ MINH – 01/2026

1. GIỚI THIỆU

Đồ án thực hiện phân tích thăm dò (EDA) bộ dữ liệu Diamonds trên Kaggle và xây dựng mô hình hồi quy dự đoán giá kim cương (price). Quy trình gồm: đọc dữ liệu bằng Pandas, làm sạch và tiền xử lý (loại bản ghi lỗi kích thước), thống kê mô tả và trực quan hóa, phân tích tương quan và kiểm định ANOVA cho biến phân loại, sau đó là các mô hình hồi quy tuyến tính (Linear Regression) đơn biến, đa biến và hồi quy đa thức (Polynomial Regression) trên Scikit-learn theo Pipeline (chuẩn hóa + One-hot Encoding + mô hình), đồng thời chọn bậc đa thức bằng cross-validation. Kết quả cho thấy dữ liệu gốc có 53,940 dòng; sau làm sạch còn 53,917 dòng. Điểm đáng chú ý là các đặc trưng liên quan kích thước (carat/volume) chi phối mạnh giá, trong khi một số biến phân loại như cut có tác động nhỏ hơn khi đã kiểm soát các biến kích thước. Mô hình tốt nhất là hồi quy đa thức bậc 3 với $R^2 \approx 0.9346$ và $RMSE \approx 1015.50$ USD trên tập kiểm tra.

Cam kết minh bạch: bộ dữ liệu sử dụng trong đồ án được tham khảo từ Kaggle – “Diamonds Dataset” (tác giả shivam2503) [1] và được nộp kèm là file diamonds.csv trong thư mục data. Nhóm tự thiết kế toàn bộ quy trình phân tích và tự viết mã nguồn, không sao chép một đồ án hoàn chỉnh nào. Tài liệu tham khảo chỉ phục vụ mục đích kỹ thuật gồm mô tả biến của bộ dữ liệu và tài liệu chính thức của Pandas/Scikit-learn [2][3]. Nếu có đối chiếu với notebook hay dự án mẫu nào, nhóm sẽ trích dẫn rõ nguồn và nộp minh chứng mã; phần nhóm tự bổ sung gồm quy trình làm sạch ngoại lệ, tạo biến volume, phân tích skewness/kurtosis, thực hiện ANOVA, xây dựng Pipeline và lựa chọn bậc đa thức bằng cross-validation, đồng thời chuẩn bị dữ liệu sạch phục vụ trực quan hóa bằng dashboard phân tích.

2. MÔ TẢ BỘ DỮ LIỆU

Bộ dữ liệu Diamonds mô tả các viên kim cương thương mại thông qua nhóm biến chất lượng gồm cut, color, clarity và nhóm biến kích thước hay vật lý gồm carat, x, y, z, depth, table, hướng tới bài toán dự đoán giá bán (price, USD). Dữ liệu được tham khảo từ Kaggle [1] và tải về ở định dạng CSV; trong đồ án, dữ liệu được đọc bằng Pandas và lưu bản gốc trong thư mục data để đảm bảo khả năng tái lập kết quả và minh bạch nguồn dữ liệu.


Kết quả kiểm tra dữ liệu ban đầu cho thấy tập dữ liệu gốc gồm 53,940 dòng và 11 cột (bao gồm cột chỉ số Unnamed: 0 trong file gốc). Nhóm không ghi nhận giá trị khuyết (missing values), tuy nhiên phát hiện một số bản ghi có x/y/z bằng 0 hoặc có giá trị ngoại lai bất thường (ví dụ y=58.9 mm), được xem là lỗi đo lường hoặc nhập liệu nên được loại khỏi quá trình phân tích. Sau bước làm sạch, tập dữ liệu còn 53,917 dòng. Ngoài các cột gốc, nhóm tạo thêm biến phát sinh volume = $x*y*z$ để biểu diễn thể tích (mm^3), nâng tổng số biến sử dụng trong phân tích lên 12 cột (11 cột gốc + 1 cột phát sinh). Bảng 1 trình bày danh sách biến, kiểu dữ liệu, phạm vi và ý nghĩa các cột trong bộ dữ liệu. Lưu ý, đây là bộ dữ liệu tham khảo từ Kaggle, không phải dữ liệu nhóm tự thu thập.

STT	Tên cột	Kiểu dữ liệu	Phạm vi/giá trị	Giải thích
1	Unnamed: 0	int64	1 - 53940	Chỉ số thứ tự (ID) của bản ghi trong file gốc.
2	carat	float64	0.2 - 5.01	Trọng lượng kim cương (carat).
3	cut	object	Fair, Good, Ideal, Premium, Very Good	Chất lượng cắt (Fair, Good, Very Good, Premium, Ideal).
4	color	object	D, E, F, G, H, I, J	Màu sắc (từ D - tốt nhất đến J).
5	clarity	object	I1, IF, SI1, SI2, VS1, VS2, VVS1, VVS2	Độ tinh khiết (I1, SI2, SI1, VS2, VS1, VVS2, VVS1, IF).
6	depth	float64	43 - 79	Tỷ lệ chiều sâu (%) = $2z/(x+y)*100$.
7	table	float64	43 - 95	Chiều rộng mặt bàn (%) so với điểm rộng nhất.
8	price	int64	326 - 1.88e+04	Giá kim cương (USD).
9	x	float64	3.73 - 10.7	Chiều dài (mm).
10	y	float64	3.68 - 10.5	Chiều rộng (mm).
11	z	float64	1.07 - 6.98	Chiều cao/độ dày (mm).
12	volume	float64	31.7 - 790	Thể tích $x*y*z$ (mm ³), là biến phát sinh.

Bảng 1. Mô tả bộ dữ liệu Diamonds.


Trên tập dữ liệu sạch, biến price dao động từ 326 đến 18,823 USD, trung bình khoảng 3,930.91 USD và trung vị 2,401 (Q1=949, Q3=5,323). Biến carat có trung vị 0.70 (min=0.20, max=5.01), trong khi volume có trung vị 114.84 mm³ (min=31.71, max=790.13). Về cấu trúc biến, bộ dữ liệu gồm 3 biến phân loại là cut (5 mức), color (7 mức), clarity (8 mức) và các biến còn lại là biến số, tạo nền tảng cho các bước tiếp theo gồm phân tích phân phối, đánh giá tương quan, kiểm định thống kê và xây dựng mô hình hồi quy dự đoán giá.

3. PHƯƠNG PHÁP PHÂN TÍCH



Hình 1. Quy trình phân tích dữ liệu.

Đồ án tiếp cận theo quy trình phân tích dữ liệu gồm các bước như hình 1: (1) thu thập và đọc dữ liệu, (2) làm sạch và tiền xử lý, (3) phân tích thăm dò và trực quan hóa, (4) xây dựng mô hình hồi quy, (5) đánh giá và lựa chọn mô hình, (6) xuất dữ liệu sạch phục vụ báo cáo và dashboard phân tích.



Hình 2. Chi tiết quy trình phân tích dữ liệu.

Giải thích Hình 2: Dữ liệu được tham khảo từ Kaggle và đọc bằng Pandas. Nhóm kiểm tra tổng quan (kích thước dữ liệu, kiểu dữ liệu, giá trị khuyết), sau đó làm sạch bằng cách loại bỏ các bản ghi lỗi kích thước (x/y/z bằng 0 hoặc ngoại lai bất thường) và tạo biến mới $\text{volume} = x \cdot y \cdot z$. Tiếp theo, nhóm thực hiện EDA gồm thống kê mô tả, trực quan hóa phân phối, đo độ lệch và độ nhọn (skewness/kurtosis), phân tích tương quan cho các biến số và kiểm định ANOVA để đánh giá khác biệt giá theo các biến phân loại.


Sau EDA, dữ liệu được tách thành tập huấn luyện và tập kiểm tra theo tỉ lệ 80/20 với `random_state=42` để đảm bảo khả năng tái lập kết quả.

Về mô hình hóa, nhóm xây dựng các mô hình hồi quy theo hướng tăng dần mức độ phức tạp. Thứ nhất là mô hình hồi quy tuyến tính đơn biến dùng carat làm baseline. Thứ hai là hồi quy tuyến tính đa biến với hai cấu hình đặc trưng số: (A) carat, depth, table, x, y, z và (B) carat, depth, table, volume; các biến phân loại cut, color, clarity được mã hóa One-hot. Toàn bộ bước tiền xử lý và mô hình được đóng gói bằng Pipeline kết hợp ColumnTransformer nhằm đảm bảo các phép biến đổi (chuẩn hóa và mã hóa) chỉ vừa vận trên tập huấn luyện, giảm rủi ro data leakage và thuận tiện khi thay đổi mô hình hoặc đặc trưng.

Đối với hồi quy đa thức (Polynomial Regression), nhóm mở rộng mô hình bằng cách áp dụng PolynomialFeatures lên nhóm biến số (cấu hình B) và thử các bậc degree $\in \{1, 2, 3\}$ (`include_bias=False`), sau đó chuẩn hóa bằng StandardScaler; nhóm biến phân loại vẫn được One-hot như trên. Để lựa chọn bậc đa thức, nhóm sử dụng Cross-validation KFold 5 phần (`n_splits=5`, `shuffle=True`, `random_state=42`) trên tập huấn luyện với thước đo R^2 ; đồng thời đánh giá lại trên tập kiểm tra bằng RMSE và R^2 . Mô hình cuối cùng được lựa chọn dựa trên nguyên tắc tổng hợp: ưu tiên RMSE thấp và R^2 cao trên tập kiểm tra, đồng thời tham chiếu kết quả ổn định của CV R^2 (mean/std) để hạn chế overfitting. Sau khi chọn mô hình tốt nhất, nhóm xuất tập dữ liệu sạch phục vụ phần báo cáo và trực quan hóa trên dashboard phân tích.

4. PHÂN TÍCH THẨM DÒ


Phần này trình bày các phát hiện chính từ EDA, tập trung vào những biến có ảnh hưởng trực tiếp đến giá và các đặc điểm phân phối dữ liệu. Nhóm ưu tiên các biểu đồ, hệ số dễ diễn giải (histogram, scatter, boxplot, heatmap) nhằm làm rõ mối quan hệ giữa biến mục tiêu price và các biến giải thích.



Hình 3. Histogram phân phối giá (price).


Giá kim cương có phân phối price tập trung mạnh ở vùng giá thấp và có đuôi kéo dài về phía giá cao, cho thấy lệch phải rõ rệt ($\text{skewness} \approx 1.6184$), đa số quan sát tập trung ở mức giá

thấp–trung bình, trong khi một số ít viên kim cương có giá rất cao tạo đuôi phải dài. Thống kê cho thấy median=2401 USD, nhưng mean≈3930.91 USD lớn hơn đáng kể do ảnh hưởng của các giá trị lớn.




Hình 4. Histogram của $\log(\text{price})$ – giảm lệch phải.

Khi biến đổi $\log(\text{price})$, phân phối trở nên cân đối hơn, giúp một số mô hình tuyến tính/đa thức phù hợp giả định nhiều gần chuẩn tốt hơn. Trong đồ án, nhóm giữ price ở thang đo gốc để dễ diễn giải RMSE (USD), đồng thời dùng $\log(\text{price})$ để minh họa kỹ thuật xử lý lệch phân phối.




Hình 5. Phân bố số lượng theo cut.

Trong biến cut, nhóm 'Ideal' chiếm tỷ trọng lớn nhất. Điều này có thể phản ánh thiên lệch thu thập (dataset bias) trên thị trường hay nguồn dữ liệu.




Hình 6. Boxplot giá theo cut.

Boxplot cho thấy giá theo cut có sự khác biệt, nhưng cần chú ý hiệu ứng nhiễu do carat. Ví dụ: median price của Ideal ≈ 1809 USD thấp hơn Premium và Fair, một phần vì median carat của Ideal chỉ ≈ 0.54 (nhỏ hơn các nhóm còn lại). Vì vậy, phân tích định lượng cần kết hợp mô hình đa biến để kiểm soát đồng thời nhiều yếu tố.




Hình 7. Scatter plot carat và price.

Giá tăng theo carat theo xu hướng phi tuyến ($\text{corr} \approx 0.9216$). Ở vùng carat lớn, tốc độ tăng giá mạnh hơn, gợi ý mối quan hệ bậc cao (đa thức) hoặc cần biến đổi đặc trưng.



Hình 8. Scatter plot volume và price.

Biến thể tích volume có tương quan rất mạnh với giá ($\text{corr} \approx 0.9235$), và thường mang ý nghĩa vật lý rõ ràng (kích thước lớn thường có giá cao).



Hình 9. Heatmap ma trận tương quan giữa các biến số.

Heatmap xác nhận nhóm biến kích thước (x, y, z, volume, carat) tương quan mạnh với price. Ngược lại, depth gần như không tương quan tuyến tính ($\text{corr} \approx -0.0107$). Kết quả này giúp lựa chọn đặc trưng ưu tiên cho mô hình và định hướng thử nghiệm hồi quy đa thức (Polynomial Regression) để bắt được quan hệ phi tuyến.

Biến phân loại	Số mức	F-statistic	P-value
cut	5	174.459	9.49e-149
color	7	289.659	< 1e-300
clarity	8	214.789	< 1e-300

Bảng 2. Kết quả kiểm định ANOVA (F-test) đánh giá ảnh hưởng biến phân loại đến price.

Kết quả ANOVA cho thấy cả cut, color và clarity đều có ảnh hưởng có ý nghĩa thống kê đến price (p-value cực nhỏ). Tuy nhiên, ANOVA chỉ phản ánh khác biệt trung bình giữa các nhóm, chưa kiểm soát đồng thời các biến số (carat, kích thước). Do đó, phần mô hình hóa sẽ sử dụng hồi quy đa biến và Pipeline để đánh giá tổng hợp.

5. KẾT QUẢ PHÂN TÍCH

Phần này tập trung vào kết quả mô hình dự đoán. Nhóm xây dựng lần lượt: (i) hồi quy tuyến tính đơn biến ($\text{price} \sim \text{carat}$) để làm baseline dễ diễn giải; (ii) hồi quy tuyến tính đa biến với cả biến số và biến phân loại (One-hot Encoding); (iii) hồi quy đa thức


(Polynomial Regression) trên các biến số chính và lựa chọn bậc tối ưu bằng Cross-validation.

5.1. THIẾT KẾ MÔ HÌNH VÀ ĐÁNH GIÁ

Dữ liệu được chia Train/Test theo tỷ lệ 80/20 với random_state cố định để tái lập. Trong các mô hình đa biến, nhóm sử dụng Pipeline kết hợp: ColumnTransformer (tách biến số và biến phân loại), StandardScaler cho biến số và OneHotEncoder cho biến phân loại, sau đó huấn luyện LinearRegression. Đối với Polynomial Regression, nhóm áp dụng PolynomialFeatures cho nhóm biến số và đánh giá các bậc degree=1..3 bằng 5-fold Cross-validation. Các thước đo sử dụng: RMSE (Root Mean Squared Error) và R^2 .

Mô hình	RMSE (USD)	R^2
Hồi quy tuyến tính (1 biến: carat)	1524.98	0.8524
Hồi quy tuyến tính đa biến (x,y,z)	1090.26	0.9246
Hồi quy tuyến tính đa biến (volume)	1122.44	0.9201
Hồi quy đa thức (degree=2)	1100.86	0.9231
Hồi quy đa thức (degree=3)	1015.50	0.9346


Bảng 3. So sánh hiệu năng các mô hình trên tập kiểm tra (Test set).



Hình 10. So sánh RMSE giữa các mô hình (Test).

5.2. LỰA CHỌN BẬC ĐA THỨC VÀ NHẬN DIỆN OVERFITTING/UNDERFITTING

Trong hồi quy đa thức (Polynomial Regression), bậc quá thấp có thể dẫn đến underfitting (mô hình không bắt được quan hệ phi tuyến giữa carat/volume và price). Ngược lại, bậc quá cao có nguy cơ overfitting và/hoặc gây mất ổn định số học khi số hạng đa thức tăng nhanh. Vì vậy, nhóm thử nghiệm degree=1..3 và chọn bậc theo tiêu chí CV R^2 trung bình cao, đồng thời kiểm tra trên tập Test.




Hình 11. Hồi quy đa thức degree vs Test RMSE và degree vs Test R².

Kết quả cho thấy degree=3 là lựa chọn tốt nhất trong phạm vi thử nghiệm: CV R² trung bình ≈ 0.9268 , Test R² ≈ 0.9346 và RMSE ≈ 1015.50 USD. Điều này phù hợp với quan sát EDA rằng quan hệ giữa price và carat/volume có xu hướng phi tuyến.


5.3. TRỰC QUAN HÓA BẰNG DASHBOARD PHÂN TÍCH

Để trực quan hóa kết quả dưới dạng dashboard phân tích, nhóm xuất dữ liệu sạch diamonds_cleaned.csv (gồm các biến quan trọng và cột log_price). Dashboard nằm ở cuối notebook, cho phép lọc theo các biến phân loại (cut/color/clarity) và cập nhật đồng thời các KPI (số bản ghi sau lọc, giá trung bình, giá trung vị, carat trung bình) cùng các biểu đồ chính: histogram phân phối giá, scatter carat–price, tỷ trọng theo cut và các biểu đồ so sánh (giá trung bình theo cut, số lượng theo color, xu hướng AVG(price) theo các khoảng carat). Cách triển khai này giúp tổng hợp nhanh các phát hiện EDA, đảm bảo tính tái lập (cùng một dữ liệu đầu vào cho ra cùng kết quả) và thuận tiện minh họa trực quan vào báo cáo.



Hình 12. Tổng quan dashboard phân tích.

Hình 12 trình bày dashboard phân tích tổng quan từ dữ liệu sạch, gồm các KPI (số bản ghi, giá trung bình/trung vị, carat trung bình) và các biểu đồ chính như histogram price và scatter carat–price. Các biểu đồ phụ (tỷ trọng cut, giá trung bình theo cut, số lượng theo color) hỗ trợ nhận diện nhanh cấu trúc dữ liệu và các yếu tố có khả năng ảnh hưởng đến giá.”



Hình 13. Dashboard phân tích sau khi dùng bộ lọc.

Hình 13 thể hiện dashboard khi áp dụng bộ lọc theo cut/color/clarity; các KPI và toàn bộ biểu đồ cập nhật đồng thời theo tập dữ liệu sau lọc. Việc đối chiếu trước–sau lọc giúp quan sát trực quan sự thay đổi mức giá (histogram/KPI) và xu hướng carat–price theo từng nhóm chất lượng, qua đó củng cố nhận định rằng các biến phân loại có liên quan đến price.

6. KẾT LUẬN

Đồ án tập trung phân tích thăm dò Diamonds Dataset và xây dựng mô hình dự đoán giá kim cương (price). Quy trình gồm: đọc dữ liệu bằng Pandas, làm sạch và tạo đặc trưng (volume = xyz), thực hiện EDA bằng thống kê mô tả và trực quan hóa, đồng thời kiểm định ANOVA để đánh giá ảnh hưởng của các biến phân loại (cut, color, clarity). Kết quả EDA cho thấy phân phối price lệch phải (skewness≈1.62) và giá phụ thuộc mạnh vào nhóm biến kích thước (carat/volume). Trên bài toán dự đoán, mô hình tốt nhất là Polynomial Regression bậc 3, đạt Test $R^2 \approx 0.9346$ và RMSE≈1016 USD, cải thiện so với hồi quy tuyến tính. Kết luận rút ra là cần kết hợp đồng thời đặc trưng kích thước và các biến chất lượng thông qua Pipeline (mã hóa One-hot + chuẩn hóa) để mô hình ổn định và dễ tái lập; việc chọn bậc đa thức bằng cross-validation giúp cân bằng overfitting/underfitting. Trong hướng phát triển, có thể thử Ridge/Lasso hoặc các mô hình cây/ensemble để tăng độ chính xác và phân tích mức độ quan trọng của đặc trưng.

TÀI LIỆU THAM KHẢO

- [1] Kaggle, “Diamonds Dataset (shivam2503)”. Link: <https://www.kaggle.com/datasets/shivam2503/diamonds> (Truy cập lần cuối: 10/01/2026).
- [2] Pandas Documentation, “pandas documentation”. Link: <https://pandas.pydata.org/docs/> (Ngày truy cập: 09/01/2026).
- [3] Scikit-learn Documentation, “Pipeline”. Link: <https://scikit-learn.org/stable/modules/generated/sklearn.pipeline.Pipeline.html> (Ngày truy cập: 12/01/2026).
- [4] Scikit-learn Documentation, “ColumnTransformer”. Link: <https://scikit-learn.org/stable/modules/generated/sklearn.compose.ColumnTransformer.html> (Ngày truy cập: 12/01/2026).
- [5] SciPy Documentation, “scipy.stats.f_oneway”. Link: https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.f_oneway.html (Ngày truy cập: 12/01/2026).

PHỤ LỤC PHÂN CÔNG NHIỆM VỤ

STT	Thành viên	Nhiệm vụ
1	Lê Hải Phúc	Thu thập, đọc dữ liệu Kaggle; làm sạch & tiền xử lý (lọc x/y/z=0, ngoại lai, tạo volume); EDA & trực quan (histogram, scatter, heatmap, skewness/kurtosis); kiểm định ANOVA; xây dựng Pipeline/ColumnTransformer (OneHotEncoder + StandardScaler); huấn luyện mô hình Linear/Polynomial + cross-validation; đánh giá (R^2 , RMSE); tạo dashboard; viết báo cáo và hoàn thiện nộp bài.